

دانشگاه فردوسی مشهد
گروه مهندسی کامپیوتر

شبکه‌های عصبی و یادگیری عمیق
تمرین ۲

گزارش پیاده‌سازی و تحلیل نتایج Weakly-Supervised Object Localization

متین نظام‌الملکی

۴۰۱۱۲۶۲۳۵۰

فهرست مطالب

۱	مقدمه	۲
۲	انتخاب لایه CAM برای هر معماری	۲
۳	PipeLine پروژه	۲
۱.۳	مرحله ۱ — تولید نقشه حرارتی	۲
۲.۳	مرحله ۲ — استخراج کادر محدودکننده از نقشه حرارتی	۳
۴	نتایج استخراج شده	۳
۱.۴	دقت دسته‌بندی	۳
۲.۴	معیارهای مکان‌یابی	۳
۵	تحلیل و بررسی	۳
۱.۵	وارونگی بین رتبه طبقه‌بندی و مکان‌یابی	۴
۲.۵	ارزیابی نسبتاً ضعیف برای معیارهای مکان‌یابی	۴
۳.۵	تاثیر پیش‌بینی لیبل بر نتایج مکان‌یابی	۴
۶	نتیجه‌گیری	۵

۱. مقدمه

هدف این پروژه انجام مکان‌یابی شیء با نظارت ضعیف روی مجموعه داده سگ‌های استنفورد (Stanford Dogs) با استفاده از چندین شبکه عصبی کانولوشنی (CNN) از پیش‌آموزش‌دیده روی ImageNet است. شبکه‌های مورد بررسی صرفاً با برچسب‌های دسته‌بندی سطح تصویر آموزش دیده‌اند، با این حال هدف ما پیش‌بینی موقعیت مکانی شیء در زمان استنتاج است.

پنج معماری به طور کامل پیاده‌سازی و ارزیابی شده‌اند: ResNet-18 ResNet-101 SqueezeNet-1.1 ConvNeXt- Tiny و GoogLeNet. در این گزارش کار به جزئیات پیاده‌سازی، خط لوله تولید نقشه حرارتی، استخراج کادر و در نهایت تحلیل نتایج به دست آمده از اجرای مدل‌ها پرداخته می‌شود.

۲. انتخاب لایه CAM برای هر معماری

کیفیت و وضوح نقشه حرارتی استخراج شده به طور حیاتی به این بستگی دارد که کدام لایه کانولوشنی به عنوان منبع نقشه‌های ویژگی انتخاب شود. در پیاده‌سازی انجام شده، از آخرین لایه ویژگی قبل از عملیات ادغام سراسری (GAP) استفاده شده است، زیرا ویژگی‌های معنایی سطح بالا را استخراج می‌کند و در عین حال مقداری وضوح مکانی را حفظ می‌کند.

جدول ۱ لایه دقیق و منبع وزن برای هر معماری را نشان می‌دهد.

مدل	لایه اتصال	اندازه نگاشت
ResNet-18	Last BasicBlock of layer4	$512 \times 7 \times 7$
ResNet-101	Last Bottleneck of layer4	$2048 \times 7 \times 7$
SqueezeNet-1.1	Last Fire module of features	$512 \times 13 \times 13$
ConvNeXt-Tiny	Last stage of model.features	$768 \times 7 \times 7$
GoogLeNet	inception5b block	$1024 \times 7 \times 7$

جدول ۱: لایه ویژگی CAM استخراج شده برای هر مدل در کد.

۳. Pipeline پروژه

۱.۳. مرحله ۱ — تولید نقشه حرارتی

گام ۱. پیش‌پردازش: هر تصویر به ابعاد 224×224 پیکسل تغییر اندازه داده شده و نرمال‌سازی شد.

گام ۲. ثبت نگاشت ویژگی از طریق **Forward Hook** روی لایه کانولوشنی مشخص شده در جدول ۱ ثبت شد تا تانسور خروجی در حین اجرای مدل ذخیره شود.

گام ۳. انتخاب کلاس پیش‌بینی شده: اندیس کلاسی که بیشترین دقت در Top-1 را از شبکه گرفت استخراج شد.

گام ۴. جمع وزن دار **feature map**: ضرب نقطه‌ای میان نگاشت‌های ویژگی و وزن‌های استخراج شده برای کلاس هدف انجام شد.

گام ۵. فعال‌ساز ReLU و نرمال‌سازی: مقادیر منفی با ReLU صفر شده و نتیجه در بازه $[0, 255]$ نرمال شد.

گام ۶. نمونه‌برداری **Bilinear upsampling**: نقشه حرارتی به ابعاد اصلی 224×224 مقیاس‌بندی شد.

۲.۳. مرحله ۲ — استخراج کادر محدودکننده از نقشه حرارتی

- گام ۱. دودویی‌سازی چندآستانه‌ای: نقشه حرارتی در سه سطح شدت ثابت $\{150, 180, 200\}$ آستانه‌گذاری شد.
- گام ۲. تبدیل فاصله و دودویی‌سازی مجدد: برای هر تصویر دودویی به‌دست‌آمده، تبدیل فاصله روی پس‌زمینه اعمال شد.
- گام ۳. تشخیص خطوط تراز (Contour detection): تابع `findContours` از کتابخانه `OpenCV` برای یافتن کادرهای کاندید اجرا شد.
- گام ۴. ادغام مبتنی بر هم‌پوشانی: کادرهای کاندید که به طور قابل توجهی هم‌پوشانی داشتند با الگوریتم پیاده‌سازی شده (`merge_overlapping_boxes`) ادغام شدند.
- گام ۵. انتخاب و مقیاس‌بندی مجدد مختصات: بزرگترین کادر نهایی انتخاب شده و مختصات آن به ابعاد تصویر اصلی (Ground-truth) برگردانده شد.

۴. نتایج استخراج شده

۱.۴. دقت دسته‌بندی

مدل	Top-1	Top-5
ResNet-18	81.75	97.25
ResNet-101	90.67	99.08
SqueezeNet-1.1	67.25	91.00
ConvNeXt-Tiny	94.67	99.67
Googlenet	70.58	92.75

جدول ۲: دقت دسته‌بندی Top-1 و Top-5

۲.۴. معیارهای مکان‌یابی

مدل	میانگین IoU	میان IoU	IoU@0.5 (%)	IoU@0.75 (%)
ResNet-18	0.4697	0.4753	44.42	4.42
ResNet-101	0.4586	0.4703	41.58	4.42
SqueezeNet-1.1	0.2295	0.1842	7.67	2.00
ConvNeXt-Tiny	0.3315	0.3096	17.25	2.17
Googlenet	0.3954	0.3826	20.17	0.75

جدول ۳: نتایج معیارهای مکان‌یابی


۵. تحلیل و بررسی

۱.۵. وارونگی بین رتبه طبقه‌بندی و مکان‌یابی

مهم‌ترین یافته هنگام مقایسه جداول ۱.۴ و ۲.۴، وارونگی رتبه بین عملکرد طبقه‌بندی و مکان‌یابی مدل‌ها در اجرای خط لوله است. مدل ConvNeXt-Tiny که با دقت بیش از ۹۴ درصد بهترین طبقه‌بند بود، در معیار مکان‌یابی در رتبه چهارم قرار می‌گیرد. در نقطه مقابل، مدل ResNet-18 به عنوان یک طبقه‌بند ضعیف، رتبه اول را در مکان‌یابی کسب می‌کند. این مسئله ممکن است به این خاطر باشد که مدل‌هایی که دقت بیشتری در طبقه‌بندی دارند، از نواحی بیشتری برای مشخص کردن طبقه استفاده می‌کنند. به بیان دیگر، این مدل‌ها پراکندگی map heat بیشتری دارند پس توانایی خود را در مکان‌یابی از دست می‌دهند.

۲.۵. ارزیابی نسبتاً ضعیف برای معیارهای مکان‌یابی


عامل مهم دیگری که در نتایج نهایی منجر به افت شدید مقادیر IoU (به خصوص IoU@0.75) شد، عدم تطابق میدان تمرکز نقشه حرارتی و حاشیه‌نویسی فایل‌های XML بود. شبکه‌ها عموماً روی چهره و سر سگ‌ها تمرکز می‌کنند (چرا که متمایزترین ویژگی نژادی است)، اما کادرهای مینا در این مجموعه داده کل بدن سگ را در بر می‌گیرند. حتی یک مکان‌یابی بی‌نقص از سر سگ نیز به دلیل مساحت کمتر نسبت به کل بدن، مقدار IoU پایینی ثبت می‌کند. این مورد نیز می‌تواند از علل وارونگی رتبه‌بندی نیز باشد.



شکل ۱: مثال‌هایی از عدم تطابق میدان‌های حرارتی و حاشیه‌نویسی‌های فایل‌های XML

۳.۵. تاثیر پیش‌بینی لیبیل بر نتایج مکان‌یابی

در تمامی مدل‌هایی که در اختیار بود، این اثر مشهود بود که پیش‌بینی برجسب صحیح، تاثیر بسیار زیادی روی مکان‌یابی هندسی داده‌ها می‌گذارد. در تمامی معماری‌ها اگر برجسب اشتباه پیش‌بینی می‌شد، اگر چه map heat هم مکان درستی را نشان دهد، اما box bounding نهایی مکانی دور از انتظار رو مشخص می‌کرد.



شکل ۲: مثالی از مکان‌یابی اشتباه معماری convnext بر اثر بیش‌بینی اشتباه برچسب

۶. نتیجه‌گیری

در این گزارش پیاده‌سازی، خط لوله کامل مکان‌یابی شیء با نظارت ضعیف از استخراج ویژگی تا تولید نقشه حرارتی و استخراج کادرهای محدودکننده با موفقیت روی ۵ معماری شبکه عصبی اجرا شد. نتایج اجرایی اثبات کرد که بهترین مدل برای طبقه‌بندی تصویر، لزوماً نقشه حرارتی بهینه‌ای برای مکان‌یابی هندسی تولید نمی‌کند و نیازمند بهینه‌سازی و تغییر الگوریتم‌های استخراج کادر، متناسب با پخش‌شدگی ویژگی‌های معماری‌های متفاوت است.